

MANUAL DETALHADO

EXTRATOR DIRF + MOTOR PREVIDENCIÁRIO

Versão 1.2.3 — Manual de operação, mecânica e auditoria

Índice

1. 1. Apresentação e finalidade
2. 2. Visão geral da mecânica
3. 3. Entrada — carregamento das DIRFs
4. 4. O que é extraído
5. 5. ■ Extração e filtros — finalidade
6. 6. ■ Extração e filtros — como usar
7. 7. ■ Agrupamento de vínculos / fontes pagadoras — conceito
8. 8. ■ Agrupamento — seleção inteligente
9. 9. ■ Agrupamento — o que a seleção NÃO faz
10. 10. ■ Classificação previdenciária — escopo
11. 11. ■ Classificação — relação com o código DIRF
12. 12. ■ Verificação — mudança de modelo na V1.2.3
13. 13. ■ Verificação — carregamento automático
14. 14. ■ Verificação — resumo anual
15. 15. ■ Verificação — tabela mensal
16. 16. ■ Verificação — detalhamento de uma competência
17. 17. Metodologia tradicional
18. 18. Metodologia progressiva
19. 19. Base histórica 2017–2026
20. 20. Mudanças dentro do mesmo ano
21. 21. Múltiplos vínculos — por que a progressiva ainda está separada
22. 22. ■ Apuração — o que está implementado
23. 23. ■ Apuração — classificações pendentes
24. 24. ■ Demonstração horizontal
25. 25. ■■ Exportação
26. 26. Validação dos totais da DIRF
27. 27. Registro bruto / auditoria
28. 28. Exemplo completo de uso
29. 29. Como interpretar uma diferença
30. 30. 13º salário
31. 31. Recomendações de trabalho
32. 32. O que a V1.2.3 já faz e o que ainda não faz
33. 33. Glossário
34. 34. Checklist rápido

1. Apresentação e finalidade

O Extrator DIRF + Motor Previdenciário é uma aplicação destinada a transformar declarações DIRF em uma base estruturada, auditável e utilizável para análise previdenciária. A aplicação foi desenhada em camadas: primeiro preserva-se a informação extraída; depois são aplicados filtros e seleções; em seguida ocorre a classificação previdenciária; a tabela histórica é consultada; por fim são produzidas verificações, apurações e demonstrações.

A regra central de segurança do projeto é a preservação do RAW. Uma seleção, desmarcação ou classificação realizada pelo usuário não deve apagar os registros originais. Isso permite retornar ao dado de origem quando uma diferença for encontrada.

2. Visão geral da mecânica

O fluxo funcional da versão 1.2.3 é:

1. Carregar uma ou mais DIRFs em PDF.
2. Extrair os blocos reconhecidos e seus campos.
3. Organizar os registros em DataFrame.
4. Calcular indicadores auxiliares, como alíquota efetiva observada.
5. Consultar e filtrar os registros.
6. Consolidar as fontes pagadoras por CNPJ, exibindo o nome como identificação principal.
7. Sugerir fontes para análise e manter outras fora da seleção inicial.
8. Classificar somente as fontes selecionadas.
9. Verificar a tabela previdenciária por ano e fonte, com cálculo mensal.
10. Apurar as categorias 11% e 20% atualmente implementadas.
11. Montar a demonstração horizontal.
12. Exportar RAW, dados normalizados, apuração e validações.

A classificação, a verificação e a apuração são camadas posteriores à extração. Elas não reescrevem o dado original.

3. Entrada — carregamento das DIRFs

Na barra lateral, o usuário seleciona uma ou mais DIRFs em PDF. A aplicação aceita múltiplos arquivos na mesma sessão.

Para cada arquivo, a rotina de extração é executada separadamente. O nome do arquivo é incorporado aos registros como `arquivo_origem` e a quantidade de páginas é preservada nos dados da declaração.

Se um arquivo apresentar erro de processamento, ele é listado na área de falhas sem impedir, necessariamente, o processamento dos demais arquivos. Se nenhum registro reconhecível for encontrado, a aplicação interrompe as etapas seguintes porque não existe base para análise.

4. O que é extraído

A extração não se limita aos três valores exibidos nas consultas simples. O registro estruturado preserva informações de identificação, natureza do rendimento, valores mensais e campos auxiliares.

Entre os campos utilizados pelo sistema estão:

- beneficiário;
- CPF, quando presente;
- nome do declarante/fonte;
- CNPJ do declarante;
- ano-calendário;
- código da receita;
- descrição do código;
- competência;
- tipo da competência;
- rendimento tributável;
- IRRF;
- Previdência Oficial;

- dependentes;
- pensão alimentícia;
- desconto simplificado;
- previdência complementar;
- compensações judiciais;
- fundo/clube;
- número do processo;
- página do PDF;
- arquivo de origem.

A existência de um campo no RAW não significa que ele seja utilizado pelo motor atual. O objetivo da camada RAW é preservar informação para usos posteriores e auditoria.

5. ■ Extração e filtros — finalidade

Esta guia tem duas funções: conferência da extração e consulta operacional.

A seção “Declarações identificadas” apresenta combinações de ano, CNPJ, nome, código de receita, descrição, página e arquivo de origem. Como a mesma informação pode aparecer em mais de um registro, a tela usa combinações distintas para evitar repetição desnecessária.

A seção “Consulta para Excel” trabalha sobre registros mensais e de 13º. O usuário pode filtrar por ano, declarante, CNPJ, código DIRF, tipo, grupo previdenciário e competência.

6. ■ Extração e filtros — como usar

Procedimento recomendado:

1. Selecione o ano para reduzir o universo.
2. Se necessário, selecione o declarante.
3. Use o CNPJ apenas quando precisar localizar uma fonte específica.
4. Filtre pelo código DIRF quando quiser investigar uma natureza de rendimento.
5. Escolha “mensal” ou “13º” em Tipo quando essa distinção for relevante.
6. Use Grupo previdenciário para conferir as classificações já atribuídas.
7. Na lista de competências, mantenha somente os meses que deseja exportar/visualizar.

O botão “COPIAR PARA EXCEL” copia o resultado filtrado para a área de transferência em formato tabulado. O que é copiado é somente o resultado da consulta; o JSON RAW continua completo.

7. ■ Agrupamento de vínculos / fontes pagadoras — conceito

O agrupamento é uma camada operacional. O sistema consolida os registros por CNPJ do declarante e apresenta o nome da fonte como identificação principal.

O CNPJ não desaparece: ele continua visível como identificador de conferência. O objetivo é evitar que o usuário precise memorizar números para reconhecer uma fonte.

Uma mesma fonte pode possuir mais de um código DIRF. Nesse caso, os códigos são apresentados juntos no cartão da fonte. A fonte continua sendo uma única unidade de seleção.

8. ■ Agrupamento — seleção inteligente

A aplicação cria uma sugestão inicial. As fontes cujos códigos estejam exclusivamente no conjunto 5706, 5557, 6800, 6813 ou 8053 são tratadas, para esta camada, como fontes financeiras/investimentos e ficam fora da seleção inicial. Também ficam fora da seleção inicial as fontes sem remuneração mensal e sem Previdência Oficial mensal.

As demais fontes são sugeridas para análise. “Sugerida” não significa “legalmente previdenciária”; significa apenas que há elementos suficientes para justificar sua análise na camada seguinte.

A aplicação permite:

- Selecionar sugeridas;
- Incluir todas;
- Limpar seleção;
- marcar/desmarcar cada fonte individualmente.

A seção de outras fontes fica recolhida para reduzir a poluição visual.

9. ■ Agrupamento — o que a seleção NÃO faz

Desmarcar uma fonte não exclui seus registros. A fonte continua no DataFrame original, no JSON RAW e na auditoria.

Da mesma forma, selecionar uma fonte não determina sua alíquota. A seleção apenas diz: “esta fonte fará parte das etapas posteriores”.

A sequência é deliberadamente separada:

Fonte encontrada → Fonte selecionada → Fonte classificada → Fonte utilizada no cálculo.

Essa separação evita que a interface transforme uma inferência de natureza do rendimento em uma conclusão automática de alíquota.

10. ■ Classificação previdenciária — escopo

A guia de classificação recebe exclusivamente as fontes selecionadas no agrupamento.

As opções atuais são:

- nao_definido;
- 11;
- 20;
- progressiva.

A classificação é manual. Ela fica registrada no estado da sessão e é aplicada por CNPJ.

A aplicação também pode exibir uma alíquota efetiva observada, obtida pela relação Previdência Oficial ÷ rendimento tributável quando a base é diferente de zero. Esse percentual é um indicador diagnóstico. Ele não é utilizado isoladamente para decidir o grupo previdenciário.

11. ■ Classificação — relação com o código DIRF

O código DIRF descreve a natureza declaratória do rendimento. Ele é uma evidência importante para análise, mas não deve ser tratado automaticamente como sinônimo de alíquota previdenciária.

Exemplos:

- 0561 — rendimentos do trabalho assalariado;
- 0588 — rendimentos do trabalho sem vínculo empregatício;
- 5928 — rendimento decorrente de decisão da Justiça Federal;
- 3533 — proventos de aposentadoria, reserva, reforma ou pensão pagos por previdência pública;
- 5706, 5557, 6800, 6813 e 8053 — códigos que, na seleção inicial desta aplicação, são tratados como fontes financeiras/investimentos.

O sistema mantém a possibilidade de o usuário incluir manualmente uma fonte inicialmente não sugerida.

12. ■ Verificação — mudança de modelo na V1.2.3

A guia de verificação passou de um teste centrado em uma única competência para uma verificação organizada por ano-calendário e fonte.

O usuário escolhe:

- Ano-calendário;
- Fonte/vínculo já selecionado no agrupamento.

A aplicação então localiza as competências mensais daquela fonte dentro do ano escolhido e executa a verificação individualmente para cada mês.

O ano serve para navegação, consolidação e resumo. A competência continua sendo a unidade real do cálculo.

13. ■ Verificação — carregamento automático

Ao escolher uma fonte, a aplicação obtém diretamente do DataFrame os registros mensais encontrados para o ano selecionado. Para cada competência, a remuneração e a Previdência Oficial da DIRF são utilizadas como valores de referência.

Isso elimina a necessidade de digitar manualmente cada mês quando o objetivo é auditar uma DIRF real.

O sistema mantém também a possibilidade de análise manual, útil para testar a matemática de uma faixa sem depender dos valores da DIRF.

14. ■ Verificação — resumo anual

O resumo anual informa:

- quantidade de competências encontradas;
- remuneração acumulada;
- Previdência Oficial acumulada na DIRF;
- contribuição calculada;
- diferença acumulada;
- quantidade de competências compatíveis;
- quantidade de competências para análise;
- quantidade sem comparação;
- quantidade sem tabela cadastrada.

O resumo não substitui a análise mensal. Ele funciona como painel de triagem: primeiro mostra se o ano parece consistente; depois permite localizar os meses que precisam de investigação.

15. ■ Verificação — tabela mensal

A tabela mensal apresenta, por competência:

- Competência;
- Metodologia;
- Tabela utilizada;
- Remuneração;
- Previdência DIRF;
- Calculada;
- Diferença;
- Status.

A diferença é calculada como “DIRF menos calculado”. Assim, valor positivo significa que a Previdência informada na DIRF é maior que o resultado calculado pela regra selecionada; valor negativo indica o inverso.

16. ■ Verificação — detalhamento de uma competência

Cada mês pode ser expandido.

O detalhamento informa:

- metodologia;
- identificador da tabela;
- teto;

- fonte registrada;
- contribuição calculada;
- Previdência informada na DIRF;
- diferença;
- faixas da tabela;
- limite inferior e superior;
- alíquota;
- base efetivamente distribuída na faixa;
- contribuição correspondente.

Esse detalhamento é a principal ferramenta para descobrir por que uma competência foi classificada como compatível ou como diferença para análise.

17. Metodologia tradicional

Na metodologia tradicional, a faixa atingida define a alíquota aplicada sobre a base inteira limitada ao teto.

Exemplo conceitual: em uma tabela tradicional de três faixas, se a base atingir a terceira faixa, a contribuição é calculada pela base limitada ao teto multiplicada pela alíquota da terceira faixa.

Isso é diferente da metodologia progressiva. O sistema mantém o campo “metodologia” na tabela histórica justamente para impedir que os dois modelos sejam confundidos.

18. Metodologia progressiva

Na metodologia progressiva, a base é repartida entre as faixas. Cada parcela recebe a alíquota correspondente e as contribuições são somadas.

Exemplo conceitual:

Faixa 1 → parcela × 7,5%

Faixa 2 → parcela × 9%

Faixa 3 → parcela × 12%

Faixa 4 → parcela × 14%

O teto limita a base total considerada. O sistema não aplica simplesmente 14% sobre toda a remuneração quando a competência é progressiva.

19. Base histórica 2017–2026

A base cadastrada é específica para Empregado, Empregado Doméstico e Trabalhador Avulso no RGPS.

A estrutura registra vigência, metodologia, faixas, alíquotas, teto e fonte.

2017, 2018 e 2019 utilizam metodologia tradicional.

Janeiro e fevereiro de 2020 utilizam metodologia tradicional.

Março de 2020 em diante utiliza metodologia progressiva.

2023 possui duas vigências cadastradas.

A competência é convertida em período mensal e comparada com as vigências cadastradas para localizar a tabela correta.

20. Mudanças dentro do mesmo ano

Não existe a premissa de que cada ano possui necessariamente uma única regra.

2020 é o exemplo mais evidente:

- 01/2020 e 02/2020 → tradicional;
- 03/2020 a 12/2020 → progressiva.

2023 também possui duas vigências na base.

Por isso, o resumo anual jamais deve calcular uma tabela única para os doze meses. A tabela é resolvida competência por competência.

21. Múltiplos vínculos — por que a progressiva ainda está separada

A classificação PROGRESSIVA está disponível, mas o motor principal ainda sinaliza a situação como em validação quando existe remuneração progressiva.

A razão é metodológica: a aplicação definitiva da progressiva precisa tratar adequadamente a soma das remunerações da competência entre vínculos, o limite máximo e a contribuição já informada/recolhida em cada fonte.

A guia ■ Verificação funciona como bancada de testes antes de transformar essa regra em cálculo automático definitivo.

22. ■ Apuração — o que está implementado

O motor atual calcula as categorias 11% e 20% conforme a lógica da planilha-base.

Para o grupo 11%:

base máxima = mínimo(remuneração 11%, teto)

contribuição máxima 11% = base máxima × 11%

Para o grupo 20%:

saldo do teto = máximo(teto – remuneração 11%, 0)

base máxima 20% = mínimo(remuneração 20%, saldo)

contribuição máxima 20% = base máxima 20% × 20%

Depois:

contribuição máxima total = máxima 11% + máxima 20%

contribuição acima do teto = contribuição recolhida – contribuição máxima total.

23. ■ Apuração — classificações pendentes

Se uma competência possui fonte selecionada, mas alguma fonte ainda está como `nao_definido`, a apuração sinaliza `CLASSIFICACAO_PENDENTE`.

Se não houver teto cadastrado para a competência, a apuração sinaliza `TETO_NAO_CADASTRADO`.

Se houver remuneração classificada como progressiva, a apuração atual sinaliza `PROGRESSIVA_EM_VALIDACAO`.

Esses estados são intencionais: o sistema prefere sinalizar uma condição que exige decisão do usuário a produzir um número aparentemente definitivo com uma regra ainda não integrada.

24. ■ Demonstração horizontal

A demonstração foi inspirada na planilha de referência do projeto.

Para cada fonte selecionada, a aplicação cria duas colunas:

- Nome da fonte | CNPJ — Remuneração;
- Nome da fonte | CNPJ — Previdência.

As linhas representam as competências mensais.

A estrutura é dinâmica. Se uma fonte for incluída no agrupamento, passa a participar da demonstração; se for retirada, deixa de participar da camada de demonstração, mas continua no RAW.

25. ■■ Exportação

A exportação disponibiliza:

- JSON completo + motor;
- CSV normalizado;
- CSV da apuração;
- JSON RAW somente.

O JSON completo registra também classificações, vínculos incluídos, tetos utilizados, tabelas históricas e validações.

O JSON RAW contém os registros extraídos sem depender da seleção posterior. Isso é importante para auditoria e para futuras versões do motor.

26. Validação dos totais da DIRF

A rotina de validação compara, quando possível, a soma dos rendimentos mensais com o total correspondente informado no bloco da DIRF.

Os agrupamentos de validação consideram elementos de origem como arquivo, página, ano, CNPJ, código, fundo/clube e processo.

O objetivo é detectar inconsistências de extração. Uma validação OK não significa que a classificação previdenciária ou o cálculo jurídico esteja correto; significa que a camada de extração passou por aquela verificação de consistência.

27. Registro bruto / auditoria

O painel final “Registro bruto / auditoria” apresenta os dados estruturados que alimentam as demais etapas.

É o ponto de retorno quando surgir uma divergência. O procedimento recomendado é:

1. localizar a competência;
2. identificar a fonte;
3. verificar o código;
4. conferir o registro RAW;
5. conferir a Previdência Oficial;
6. conferir a tabela histórica;
7. somente depois avaliar a regra previdenciária aplicável.

28. Exemplo completo de uso

Suponha que uma DIRF contenha dezessete fontes pagadoras.

Primeiro, o agrupamento consolida cada CNPJ em uma fonte. Fontes exclusivamente financeiras ficam fora da seleção inicial; fontes com natureza potencialmente previdenciária são sugeridas.

O usuário confirma seis fontes. A Classificação passa a mostrar somente essas seis.

Uma das fontes é classificada como PROGRESSIVA. Na Verificação, o usuário escolhe 2022 e essa fonte. O sistema carrega automaticamente os meses de 2022 encontrados na DIRF, calcula cada mês pela tabela de 2022 e compara com a Previdência Oficial.

Se fevereiro estiver compatível e março apresentar diferença, o usuário expande março e vê as faixas, bases, alíquotas e valores. A partir daí pode investigar o registro RAW antes de qualquer conclusão.

29. Como interpretar uma diferença

Uma diferença entre DIRF e cálculo não deve ser interpretada automaticamente como erro da DIRF ou do sistema.

Possíveis causas a investigar incluem:

- classificação incorreta da fonte;
- natureza específica do rendimento;
- múltiplos vínculos;
- remuneração que precisa ser tratada conjuntamente;
- competência ou vigência incorreta;
- tratamento distinto do 13º;
- diferença de arredondamento;
- informação da DIRF que não corresponde à base utilizada no teste;
- regra previdenciária específica que ainda não esteja implementada.

A função da V1.2.3 é tornar a diferença localizável e auditável.

30. 13º salário

Os registros de 13º são mantidos separados dos registros mensais.

Na consulta, o tipo de competência permite distinguir “mensal” de “13º”. A demonstração horizontal utiliza os registros mensais.

Na análise previdenciária, o 13º não deve ser somado automaticamente à remuneração mensal para enquadramento da tabela progressiva. Qualquer tratamento específico deve ser feito na regra correspondente.

31. Recomendações de trabalho

Para uma análise profissional, recomenda-se:

- trabalhar com uma cópia dos PDFs originais;
- manter o JSON RAW exportado;
- registrar quais fontes foram incluídas no agrupamento;
- registrar a classificação atribuída a cada fonte;
- utilizar a Verificação antes de confiar na progressiva;
- guardar os resultados com as diferenças encontradas;
- não interpretar uma diferença isolada sem consultar o registro RAW;
- não misturar categorias previdenciárias distintas sem regra própria.

32. O que a V1.2.3 já faz e o que ainda não faz

Já implementado:

- extração estruturada;
- preservação RAW;
- filtros;
- agrupamento por fonte/CNPJ;
- seleção inteligente;
- classificação 11%, 20% e progressiva;
- histórico 2017–2026;
- verificação anual com cálculo mensal;
- motor 11%/20%;
- demonstração horizontal;
- exportações;
- validação de totais.

Ainda em validação:

- integração definitiva da progressiva ao motor principal;
- tratamento completo de múltiplos vínculos na progressiva;
- regras específicas que dependam de categorias previdenciárias diferentes do escopo atual.

33. Glossário

RAW — camada dos registros extraídos, preservada como fonte de auditoria.

Fonte pagadora/declarante — unidade consolidada pelo CNPJ para a seleção operacional.

Competência — mês de referência do cálculo, no formato AAAA-MM.

Ano-calendário — ano usado como nível de navegação e consolidação na verificação anual.

Código DIRF — código declaratório da natureza do rendimento.

Alíquota efetiva observada — Previdência Oficial dividida pelo rendimento tributável, usada apenas como diagnóstico.

Tabela histórica — conjunto de faixas, alíquotas, teto, vigência e metodologia aplicável.

Metodologia tradicional — faixa atingida define a alíquota aplicada sobre a base inteira limitada ao teto.

Metodologia progressiva — cada parcela da base é tributada pela alíquota de sua faixa.

Vínculo operacional — fonte agrupada pelo CNPJ para as etapas do sistema; não constitui, isoladamente, conclusão jurídica.

34. Checklist rápido

- Carreguei todas as DIRFs necessárias.
- Conferi os blocos e registros identificados.
- Mantive o JSON RAW salvo.
- Revisei as fontes sugeridas.
- Verifiquei as fontes fora da seleção inicial.
- Confirmei as fontes que realmente participarão.
- Classifiquei somente as fontes selecionadas.
- Testei a progressiva pela guia de Verificação.
- Analisei as competências com diferença.
- Conferi o RAW antes de interpretar divergências.
- Revisei a Apuração.
- Conferi a Demonstração horizontal.
- Exportei os resultados e a base RAW.

Anexo A — Estrutura lógica resumida

DIRF PDF → Extração e preservação RAW → Filtros → Agrupamento → Seleção → Classificação → Verificação histórica → Apuração → Demonstração → Exportação/Auditoria

Anexo B — Base histórica cadastrada

Período	Metodologia	Faixas	Teto
2017	Tradicional	8% / 9% / 11%	R\$ 5.531,31
2018	Tradicional	8% / 9% / 11%	R\$ 5.645,80
2019	Tradicional	8% / 9% / 11%	R\$ 5.839,45
Jan–Fev/2020	Tradicional	8% / 9% / 11%	R\$ 6.101,06
Mar–Dez/2020	Progressiva	7,5% / 9% / 12% / 14%	R\$ 6.101,06
2021	Progressiva	7,5% / 9% / 12% / 14%	R\$ 6.433,57
2022	Progressiva	7,5% / 9% / 12% / 14%	R\$ 7.087,22
Jan–Abr/2023	Progressiva	7,5% / 9% / 12% / 14%	R\$ 7.507,49
Mai–Dez/2023	Progressiva	7,5% / 9% / 12% / 14%	R\$ 7.507,49
2024	Progressiva	7,5% / 9% / 12% / 14%	R\$ 7.786,02
2025	Progressiva	7,5% / 9% / 12% / 14%	R\$ 8.157,41
2026	Progressiva	7,5% / 9% / 12% / 14%	R\$ 8.475,55

Fonte histórica de referência: página “Tabela de contribuição – histórico” do INSS fornecida para o projeto. O documento oficial apresenta, entre outras, as tabelas de 2017, 2018, 2019 e janeiro–fevereiro de 2020.